

# **EDA REPORT**

*Autor: Dominik Kilian*

## Spis treści

1.	Wstęp .....	3
2.	Opis zbioru danych .....	3
3.	Metodologia .....	3
4.	Wyniki analizy .....	4
	Uszkodzone dane .....	4
	Rozmiary obrazów .....	4
	Współczynnik proporcji (Aspect Ratio) .....	5
	Kanały kolorów .....	5
	Jasność .....	6
	Etykiety (bounding box'y).....	8
5.	Interpretacja wyników .....	9
	Rozmiary obrazów & Aspect ratio .....	9
	Kanały kolorów .....	9
	Jasność .....	9
	Etykiety.....	10
6.	Odpowiedzi na pytania .....	10
	Jaka jest jakość danych? .....	10
	Jakie wzorce i trendy występują w danych? .....	10
	Jakie problemy należy rozwiązać przed modelowaniem? .....	10
	Jakie założenia okazały się prawdziwe, a jakie nie? .....	10
	Jakie nowe pytania pojawiły się podczas EDA? .....	10
7.	Recomendacje .....	10
	Strategie preprocessingu.....	10
	Wybór modelu.....	11
	Rozszerzenie zbioru .....	11

# 1. Wstęp

- **Cel zbioru i relacja z projektem dyplomowym:**

Zbiór danych został przygotowany na potrzeby projektu dyplomowego dotyczącego detekcji osób (Human Detection) w systemach monitoringu wizyjnego (CCTV). Celem jest wytrenowanie modelu zdolnego do identyfikacji sylwetek ludzkich w zróżnicowanych warunkach obserwacyjnych.

- **Uzasadnienie przeprowadzenia EDA:**

Eksploracyjna analiza danych jest niezbędna, aby ocenić jakość techniczną obrazów, zidentyfikować błędy w adnotacjach, zrozumieć charakterystykę warunków oświetleniowych oraz wykryć ewentualne anomalie. Zrozumienie i optymalizacja zbioru danych przed fazą modelowania pozwala na uzyskanie modelu lepszej jakości

## 2. Opis zbioru danych

Dane zostały pobrane z platformy (<https://roboflow.com/>). Oparte są na zdjęciach z systemów monitoringu CCTV. Główny zbiór danych został zsyntezowany z 3 zbiorów:

1. <https://universe.roboflow.com/project-d4kos/human-cctv/dataset/1>
2. <https://universe.roboflow.com/heystest/sourced-human-detection-cctv>
3. <https://universe.roboflow.com/dogan-cwk30/human-cctv-igzff>

Łączna liczba zdjęć w zbiorze to **11 249**, zdjęcia są w formacie JPG.

Dane są udostępnione na licencji **Creative Commons Attribution 4.0 International (CC BY 4.0)**. Jest to jedna z najbardziej otwartych licencji, pozwalająca na szerokie wykorzystanie zasobów w celach naukowych lub komercyjnych.

## 3. Metodologia

Proces łączenia zbiorów danych przeprowadzono z wykorzystaniem autorskiego skryptu w języku Python. W trakcie syntezy dokonano wstępnej eliminacji duplikujących się obrazów, które występowały w różnych zestawach źródłowych.

Analiza EDA została przeprowadzona w środowisku programistycznym PyCharm przy użyciu narzędzia Jupyter Notebook.

Wykorzystane biblioteki:

- **OpenCV** (<https://pypi.org/project/opencv-python/>)
- **pandas** (<https://pypi.org/project/pandas/>)
- **Matplotlib** (<https://pypi.org/project/matplotlib/>)
- **Numpy** (<https://pypi.org/project/numpy/>)
- **seaborn** (<https://pypi.org/project/seaborn/>)
- **Pillow** (<https://pypi.org/project/pillow/>)


## 4. Wyniki analizy

### Uszkodzone dane

Brak obrazów uszkodzonych lub o niepoprawnej strukturze pliku.

### Rozmiary obrazów

Wykres rozkładu wymiarów obrazów pokazuje, że większość próbek posiada orientację poziomą (szerokość większa niż wysokość), co jest typowe dla nagrani z kamer monitoringu. Widoczne są wyraźne skupiska punktów odpowiadające dominującym rozdzielczościom. Widać również pojedyncze wartości odstające, reprezentujące obrazy o bardzo wysokich rozdzielczościach, wykraczających poza standardowy zbiór



### 5 Najczęściej występujących rozdzielczości:


Szerokość (w px)	Wysokość (w px)	Liczność
1920	1080	5504
640	640	3997
1280	720	499
256	256	264
3840	2160	167

W strukturze zbioru wyraźnie dominują dwa standardy rozdzielczości: **Full HD (1920×1080)**, który obejmuje blisko połowę wszystkich próbek (~49%), oraz format kwadratowy **640×640**, stanowiący ponad jedną trzecią (~36%). Łącznie te dwie konfiguracje odpowiadają za blisko 85% całego zbioru.

## Współczynnik proporcji (Aspect Ratio)

Widoczne są dwie dominujące grupy:

- Pierwsza grupa znajduje się w okolicach wartości 1.0, co oznacza obrazy zbliżone do **formatu kwadratowego 1:1**.
- Druga, znacznie liczniejsze skupisko występuje w okolicach wartości około 1.7–1.8, co odpowiada **formatowi 16:9 lub zbliżonym**.




## Kanały kolorów

Wyniki analizy wykazały, że wszystkie obrazy w zbiorze posiadają trzy kanały kolorów (RGB). Nie zidentyfikowano obrazów w skali szarości (1 kanał), formacie RGBA (4 kanały) ani w innych niestandardowych formatach.

Format	Liczność
GRAYSCALE	0
RGB	11249
RGBA	0
INNE	0

Pomimo że wszystkie obrazy zostały zapisane w formacie RGB, analiza różnic międzykanałowych wykazała, że **19,17% zbioru stanowią próbki o charakterze achromatycznym** (wizualnie czarno-białym), potwierdza to wysoka korelacja między poszczególnymi kanałami.


	R	G	B
ŚREDNIA	117.982	118.985	115.382
ODCHYLENIE STANDARDOWE	60.405	60.703	61.649



#### Wskaźniki statystyczne kanałów RGB

- **Średnia:** Wartości są do siebie zbliżone, oscylują wokół połowy zbioru z lekkim przesunięciem w stronę ciemniejszych tonów. Oznacza to, że zbiór nie jest ani zbyt prześwietlony ani bardzo ciemny, kolory są zbalansowane.
- **Std:** Wartość ~61 sugeruje, że obrazy w zbiorze cechują się dużą zmiennością jasności.

Z wykresu przedstawiającego histogram wartości pikseli dla trzech kanałów kolorów (R, G, B), widzimy, że krzywe się niemal pokrywają, co oznacza, że w zbiorze nie ma dominacji jednego koloru, kolorystyka jest zrównoważona.



## Jasność


W analizie jasności obrazów wykorzystano percentile 5. i 95., które opisują odpowiednio poziom najciemniejszych oraz najjaśniejszych fragmentów obrazu.

### Wskaźniki statystyczne percentyl:

- Średni 5. percentyl: ~26,3
- Średni 95. percentyl: ~204,56
- Szerokość tonalna (średni 95. percentyl - średni 5. percentyl): ~178,3


Z obliczonych wskaźników oraz wykresów rozkładu dla percentylów można wnioskować, że obrazy zachowują informacje (wysoką czytelność detali) zarówno w ciemnych jak i jasnych fragmentach. Wysoka szerokość tonalna sugeruje, że na zdjęciach wyraźny jest kontrast między ciemnymi i jasnymi partiami, co ułatwia modelowi poprawną separację sylwetek od otoczenia.

### Analiza zakresu jasności obrazów




Szeroki zakres rozkładu jasności pikseli pokazuje obecność zróżnicowanych warunków oświetleniowych (sceny dzienne oraz nocne).

### Rozkład jasności pikseli (Grayscale)



Rozkład średniej jasności obrazów wskazuje, że większość próbek charakteryzuje się zrównoważonym poziomem luminancji, oscylującym wokół środkowych wartości. Ekstremalne przypadki - obrazy bardzo ciemne lub bardzo jasne – występują rzadko i stanowią niewielką cześć zbioru.

**Rozkład średniej jasności na obraz**




Dodatkowo przeprowadzona została analizę przypadków odstających pod względem jasności oraz kontrastu. Za obrazy bardzo ciemne uznano te, dla których 95. percentyl jasności był niższy niż 50, natomiast jako obrazy o niskim kontraście zdefiniowano próbki o szerokości tonalnej mniejszej niż 40.

W całym zbiorze zidentyfikowano jedynie 1 obraz bardzo ciemny oraz 3 obrazy o niskim kontraście. Oznacza to, że wizualnie nieczytelne lub problematyczne przypadki praktycznie nie występują, a jakość luminancji danych jest wysoka.


## Etykiety (bounding box'y)

Wykres przedstawia liczbę obrazów w zależności od liczby oznaczonych osób (bounding boxów) w danej próbce. Widać, że dane głównie zawierają sceny o niskim zagęszczeniu, obrazy o wysokim zagęszczeniu stanowią mniejszość.



Zidentyfikowano **163** obrazy bez adnotacji: ~1,5% całego zbioru.

Podczas analizy wykryto **4** anomalie – zdjęcia bez etykiet pomimo widocznej obecności osoby na zdjęciu.



## 5. Interpretacja wyników

### Rozmiary obrazów & Aspect ratio:

Analiza wymiarów obrazów wykazała, że zbiór nie jest jednorodny pod względem rozdzielczości ani proporcji. W trakcie budowania modelu trzeba pamiętać o ujednoliceniu danych wejściowych do tego samego rozmiaru.

### Kanały kolorów:

Analiza wykazała silną korelację między kanałami kolorów, co wskazuje, że w wielu przypadkach informacje niesione przez kanały R, G i B są do siebie bardzo zbliżone. Znaczna część zbioru (ok. 19%) stanowią obrazy bliskie skali szarości. W kontekście detekcji obiektów nie stanowi to istotnego ograniczenia, ponieważ modele detekcyjne (np. YOLO) w dużej mierze opierają się na cechach strukturalnych, takich jak krawędzie i kształty, a informacja kolorystyczna ma zwykle charakter pomocniczy.

### Jasność:

Analiza wykazała, że większość obrazów charakteryzuje się zrównoważoną jasnością oraz szerokim zakresem kontrastu. Rozkład percentylów wskazuje, że obrazy zachowują szczegóły zarówno w cieniach, jak i w jasnych partiach. Zbiór cechuje się dobrą jakością luminancji i nie wykazuje istotnych problemów związanych z niedoświetleniem ani prześwietleniem.

## Etykiety:

Analiza adnotacji wykazała, że zbiór jest zdominowany przez obrazy zawierające niewielką liczbę osób. Oznacza to, że model będzie trenowany głównie na scenach o niskiej gęstości, co może ograniczać jego skuteczność w przypadkach silnie zatłoczonych scen.

Zidentyfikowano 163 obrazy bez osób. Jest to znikoma liczba w kontekście całego zbioru, w dodatku większość z nich nie odzwierciedla typowych warunków kamer CCTV, dlatego w dalszych etapach warto rozważyć ich usunięcie lub zastąpienie bardziej reprezentatywnymi przykładami tła.

Dodatkowo wykryto 4 przypadki błędnych oznaczeń - obrazy zawierające osoby bez przypisanych bounding boxów. Choć ich liczba jest marginalna, wymagają one korekty w celu zapewnienia pełnej spójności zbioru treningowego.

## 6. Odpowiedzi na pytania

### Jaka jest jakość danych?

Jakość danych można ocenić jako wysoką.

### Jakie wzorce i trendy występują w danych?

- Dominacja scen z małą liczbą osób (1–4).
- Dwie główne proporcje obrazów (format zbliżony do 1:1 oraz ~16:9).
- Silna korelacja między kanałami RGB.
- Około 19% obrazów zbliżonych do skali szarości.

### Jakie problemy należy rozwiązać przed modelowaniem?

- Ujednolicenie rozmiaru wejściowego obrazów przy zachowaniu proporcji.
- Usunięcie błędnych adnotacji.
- Podjęcie decyzji dotyczącej obrazów bez osób (usunięcie lub zastąpienie bardziej reprezentatywnymi przykładami tła).

### Jakie założenia okazały się prawdziwe, a jakie nie?

- Błędne założenie, że każde zdjęcie zawiera osobę.
- Poprawne założenie, że zbiór obejmuje różne warunki oświetleniowe.

### Jakie nowe pytania pojawiły się podczas EDA?

- Czy model będzie skuteczny w scenach o dużym zagęszczeniu?
- Czy warto rozszerzyć zbiór o sceny bezosobowe?

## 7. Recomendacje

### Strategie preprocessingu:

- Przy skalowaniu obrazów do stałego rozmiaru warto rozważyć technikę zachowującą proporcje unikającą deformacji sylwetek. Jedną z takich technik jest skalowanie typu **letterbox**.

- Z uwagi na niską rolę koloru w zbiorze warto sprobować technik augmentacyjnych, zmieniających kanały kolorów, np. **RandomGrayscale** polegającej na losowym przekształcaniu kolorowych obrazów wejściowych (RGB) w obrazy czarno-białe (w skali szarości) podczas procesu trenowania modelu. Random Grayscale uczy model, że błędy kolorystyczne nie mają znaczenia dla poprawnego rozpoznania człowieka.

### Wybór modelu:

Dla problemów detekcji domyślnym wyborem są modele z rodziny YOLO.

### Rozszerzenie zbioru:

W celu zwiększenia skuteczności modelu oraz poprawy jego zdolności generalizacji warto rozważyć:

- Zwiększenie liczby obrazów bez osób, co może przyczynić się do redukcji fałszywych detekcji.
- Rozszerzenie zbioru o sceny o dużym zagęszczeniu osób, aby poprawić skuteczność detekcji w bardziej złożonych przypadkach.